

LE ROBOT MAGICIEN QUI DESSINE TOUT CE QUE TU IMAGINES.



GAN, VAE, Diffusion Models : comprendre les trois grandes architectures du Generative AI en Computer Vision

1 INTRODUCTION

Imagine que tu as un ami qui a regardé des millions de photos toute sa vie comme chats, paysages, visages, voitures. Après tout ça, il peut dessiner de nouvelles images de toutes pièces, juste en imaginant. C'est exactement ce que fait le Generative AI appliqué à la Computer Vision.

Generative AI en CV, c'est apprendre à une machine à comprendre des images... puis à en inventer de nouvelles. Elle ne copie pas : elle crée.

La Computer Vision (CV) classique, ça sert à reconnaître des choses dans des images. Le Generative AI est parti plus loin : il génère de nouvelles images qui n'ont jamais existé, modifie des photos, ou transforme du texte en image

2 MOTIVATION

La question c'est : **Pourquoi utiliser le GenAI ?**

Le GenAI en CV permet d'augmenter les données, de créer du contenu, de comprendre le monde visuel et d'innover dans des domaines où les données sont rares. C'est un super-pouvoir pour l'IA !

3 LES ARCHITECTURES


Il existe trois familles principales de modèles génératifs pour la vision. Chacune a sa propre manière pour apprendre à créer des images.

1- GAN: GENERATIVE ADVERSARIAL NETWORK

Imagine deux personnes — un faussaire qui essaie de peindre de fausses peintures pour les faire passer pour des vrais Picasso, et un détective expert qui doit distinguer les vrais des faux. Ils se battent sans cesse : le faussaire s'améliore pour mieux tromper, le détective s'améliore pour mieux détecter.

Comment ça marche ?

- Le Générateur (G) part de bruit aléatoire (des chiffres au hasard) et crée une fausse image.
- Le Discriminateur (D) reçoit des vraies images et la fausse image, et doit dire laquelle est fausse.
- Si D se trompe, G reçoit un "bravo !". Si D voit juste, G reçoit un "essaie encore !". Le score de D remonte pour lui aussi.
- Ce combat s'appelle entraînement adversarial. Avec le temps, G devient si bon que D ne peut plus distinguer vrai du faux.



2- VAE — Variational Autoencoder

Imagine que tu es un géographe qui explore un pays inconnu. Tu crées d'abord une carte compressée du pays (en notant juste les caractéristiques importantes : il y a des montagnes, des plages, des forêts). Ensuite, en pointant un endroit au hasard sur cette carte, tu peux reconstruire un nouveau paysage qui ressemble au pays mais qui n'existe pas encore. La carte, c'est l'espace latent !

Comment ça marche ?

- L'Encodeur lit une image et la résume en deux choses : une moyenne (μ) et un écart-type (σ) — pas une valeur fixe, mais une distribution de probabilité.
- On tire au sort un point z dans cet espace latent (via le "reparameterization trick").
- Le Décodeur prend ce point z et reconstruit une image. L'objectif : que la reconstruction ressemble à l'original.
- Pour générer : on tire un z au hasard directement dans l'espace latent (sans passer par l'encodeur), et le décodeur crée une image inédite.

5


CONCLUSION

Le Generative AI en Computer Vision, c'est apprendre aux machines à voir le monde... puis à l'imaginer. GAN, VAE et Diffusion Models sont trois philosophies différentes pour atteindre ce même objectif magique : créer des images qui n'existent pas encore.

3-Diffusion Models

Imagine une belle photo d'un chat. Tu commences à lui ajouter de la neige (du bruit) petit à petit, jusqu'à ce que l'image ne soit plus qu'un nuage de pixels aléatoires. Un modèle de diffusion apprend à faire l'opération inverse : à partir de neige pure, il apprend à enlever la neige étape par étape jusqu'à retrouver une image nette. Mais en réalité, la « neige » peut cacher n'importe quelle image qu'on lui demande de créer ! Comment ça marche ?

- Phase d'entraînement (Forward) : On prend une vraie image et on lui ajoute du bruit gaussien à chaque étape, de $t=0$ (image propre) à $t=T$ (bruit pur).
- Ce que le modèle apprend : Un réseau (souvent U-Net) apprend à prédire le bruit ajouté à chaque étape — il apprend à "voir sous la neige".
- Génération (Reverse) : On part de bruit pur aléatoire et on applique le modèle en sens inverse, T fois, pour enlever le bruit progressivement.
- Guidance par texte : Un prompt (ex: "un chat roux sur la lune") conditionne chaque étape via CLIP, orientant la débruitage vers l'image souhaitée.



4

COMPARAISON

Critère	GAN	VAE	Diffusion
Idée	Un faussaire contre un détective	On résume, on modifie la recette, on développe	On part du bruit total, on enlève le bruit petit à petit
Avantages	Images très nettes, réalistes	Stable, ne s'effondre pas, couvre bien les variantes	Qualité immense, pas d'effondrement, contrôle précis
Limites	Instable (le détective trop fort ou trop faible), modes effondrés	Images floues, moins détaillées	Très lent (beaucoup d'étapes), lourd à entraîner